

Segmentação do Ventrículo Esquerdo em Imagens de Ecocardiograma 2D pela Rede Neural Convolucional U-Net

Daniel Campos da Silva
Instituto de Informática
Universidade Federal de Goiás
Goiânia-GO, Brasil
dante_campos@discente.ufg.br

Gabriel Martins Gomes
Instituto de Informática
Universidade Federal de Goiás
Goiânia-GO, Brasil
gabriel.martins@discente.ufg.br

Gustavo Machado Leal
Instituto de Informática
Universidade Federal de Goiás
Goiânia-GO, Brasil
gustavoleal@discente.ufg.br

Mariana Dourado Ximenes de Sena Santos
Instituto de Informática
Universidade Federal de Goiás
Goiânia-GO, Brasil
marianadourado@discente.ufg.br

Rafael Langaro Passarinho
Instituto de Informática
Universidade Federal de Goiás
Goiânia-GO, Brasil
rafael.passarinho@discente.ufg.br

William Teixeira Pires Junior
Instituto de Informática
Universidade Federal de Goiás
Goiânia-GO, Brasil
williamtpjunior@discente.ufg.br

Resumo—Identificar e segmentar câmaras do coração é de suma importância para o diagnóstico médico. Sendo assim, este trabalho implementa a rede neural convolucional U-Net para realizar a segmentação do ventrículo esquerdo do coração em imagens de ecocardiograma 2D com visão de 2 e 4 câmaras. Foi utilizado o conjunto de dados CAMUS, com imagens de 450 pacientes anotadas por médicos especialistas. Ao final, foi obtido um coeficiente de Dice de 98%, demonstrando alta eficácia em relação a trabalhos anteriores.

Index Terms—u-net, convolutional, neural network, segmentation, echocardiogram

I. INTRODUÇÃO E OBJETIVOS

O trabalho de delimitar as regiões do coração em uma imagem de ecocardiograma 2D demanda a disponibilidade de um clínico especialista que realiza a marcação manual para cada imagem e se submete a variações inter e intra especialista numa tarefa laboriosa e repetitiva. Entretanto, com o auxílio dos modernos métodos de processamento e segmentação de imagens é possível automatizar esse trabalho para elevação de níveis de eficiência e eficácia de tempo clínico [1].

A fim de realizar a segmentação automática de uma imagem, algoritmos de aprendizado de máquina supervisionado são utilizados, resultando em um modelo de predição. Para garantir o bom funcionamento desse modelo, é necessário um conjunto de dados robusto, notadamente difícil de se encontrar gratuitamente na área da saúde. Foi utilizado o *CAMUS dataset* [2], composto de imagens de ecocardiograma 2D e suas respectivas segmentações realizadas por especialistas. Durante o desenvolvimento do trabalho, foram encontrados diversos artigos que propuseram diferentes soluções para este problema utilizando os mesmos dados [3]–[7]. Dessa forma, chegou-se à conclusão de que a técnica mais bem estabelecida para segmentação de imagens médicas é a de Redes Neurais

Convolucionais (RNC). Mais especificamente, o modelo *U-Net* possui os melhores resultados dentre outros modelos para problemas não específicos [1].

Dado o escopo do trabalho, foi definido como objetivo o treinamento supervisionado da *U-Net* para segmentação do ventrículo esquerdo do coração em imagens de ecocardiograma 2D presentes no *CAMUS dataset*. Além disso, a verificação da robustez do modelo mediante a interpretação dos resultados obtidos por este também é um dos objetivos do trabalho.

Na Seção II é descrito o experimento, a rede neural e o conjunto de dados; na Seção III são expostos os resultados obtidos e; na Seção IV esses resultados são interpretados de acordo com os objetivos propostos.

II. MATERIAIS E MÉTODOS

A base de dados *CAMUS Dataset* [2] é composta por um conjunto de imagens, resultadas do exame de ecocardiograma 2D, realizados em 500 pacientes e suas respectivas anotações manuais feitas por especialistas. Para cada paciente há sequências de visualização do corte apical de duas e quatro câmaras do coração, em movimentos de diástole e sístole.

Os dados apresentam certa heterogeneidade. Enquanto 450 dos pacientes receberam anotação de um único especialista, os outros 50 foram avaliados por três cardiologistas, porém suas anotações não foram disponibilizadas. Para realizar o treinamento e teste do modelo foi utilizado o maior conjunto de imagens, para os quais têm-se os rótulos para avaliação do modelo.

A arquitetura de rede neural convolucional *U-Net* representada na Figura 1 tem se mostrada eficiente para segmentação de imagens médicas [8]. Dessa forma, foi escolhida para operar sobre as imagens de ecocardiograma em questão.




Figura 1. arquitetura *U-Net* (exemplo com 32x32 píxeis na resolução mais baixa). Cada retângulo azul corresponde a um mapa de características com múltiplos canais (a quantidade exata está anotada acima do retângulo). O tamanho x-y se encontra na borda inferior esquerda do retângulo. Retângulos brancos representam mapas de características copiados. As setas denotam diferentes operações.

A biblioteca utilizada para implementação da *U-Net* foi a *Keras*, que disponibiliza uma interface simples e permite fácil modelagem de uma rede neural. Como algoritmo de otimização para a taxa de aprendizado da rede foi escolhido a opção *Adam* [9]. Já para a função de perda foi selecionada *Sparse Categorical Crossentropy*. Por fim, apesar de não ser ideal, a principal métrica utilizada para avaliação do treinamento da rede foi a acurácia, uma vez que outras métricas exigiriam modificação em funções internas da *Keras* devido ao estado incompleto das imagens geradas durante o aprendizado, exigindo pós-processamento antes da aplicação das métricas.

Por fim, visando a avaliação do modelo proposto, foram utilizadas com métricas o Coeficiente de Dice e o coeficiente de *Intersection over Union*.

III. RESULTADOS

Foram utilizadas as imagens dos primeiros 400 pacientes para treinamento com 200 épocas, enquanto os últimos 50 pacientes ficaram no conjunto de validação. Notou-se que após poucas épocas a acurácia no conjunto de validação deixava de apresentar melhorias enquanto no conjunto de treinamento a acurácia mantinha uma melhoria contínua, representando um sobreajuste – ou mais comumente conhecido *overfitting* – do modelo aos dados de treino. O resultado para este teste foi um Coeficiente de Dice de 92% e um coeficiente de *Intersection over Union* (IoU) de 87%.

Por fim dividimos as imagens dos 450 pacientes em 5 conjuntos homogêneos para realização da validação cruzada, onde em cada iteração, um dos conjuntos será escolhido para validação enquanto o restante será utilizado no treinamento, buscando obter uma maior generalização da rede neural e consequentemente reduzindo o sobre ajuste observado anteriormente. Cada iteração executou 50 épocas e como resultado, observou-se um Coeficiente de Dice de 98% e um coeficiente de IoU de 97%. As Figuras 2 e 3 apresentam, utilizando o

coeficiente de IoU, a pior e a melhor segmentação, respectivamente, obtidas utilizando a rede neural convolucional *U-Net*.

Predição com Menor IOU




Figura 2. Ilustração do resultado de segmentação para uma imagem de ecocardiograma 2D. A primeira, segunda e terceira coluna apresentam a predição realizada pelo nosso modelo, a segmentação manual e a imagem original, respectivamente.

Predição com Maior IOU




Figura 3. Ilustração do resultado de segmentação para uma imagem de ecocardiograma 2D. A primeira, segunda e terceira coluna apresentam a predição realizada pelo nosso modelo, a segmentação manual e a imagem original, respectivamente.

Tabela I
COMPARAÇÃO DE PERFORMANCE DE SEGMENTAÇÃO ENTRE O MÉTODO PROPOSTO E TÉCNICAS RELACIONADAS USANDO O *CAMUS dataset*.

Artigo	Coeficiente de Dice
Este artigo	0.98
[3]	0.97
[4]	0.93
[5]	0.85
[6]	0.95
[7]	0.92

IV. CONCLUSÃO

Em um ambiente clínico real da área da saúde, uma segmentação errônea tem grande impacto na avaliação da funcionalidade cardíaca de um paciente e em futuras intervenções cardíacas guiadas por imagem [3]. Nesse sentido, o

modelo de rede neural convolucional *U-Net* treinada e validada sobre a base de dados *CAMUS* apresentou resultados mais satisfatórios do que artigos que utilizaram variações da *U-Net* na mesma base de dados, levando em consideração a métrica do coeficiente de Dice [3]–[7], como mostra a Tabela I.

Trabalhos futuros podem focar na utilização de variações da rede neural convolucional *U-Net*, além de outras abordagens de aprendizado profundo baseado em segmentação, como o *Densenet* e *Segnet*. Propomos também realizar a técnica de *data augmentation* no conjunto de treinamento do *CAMUS dataset*.

REFERÊNCIAS

- [1] N. Azarmehr, X. Ye, S. Sacchi, J. P. Howard, D. P. Francis e M. Zolgharni, “Segmentation of left ventricle in 2D echocardiography using deep learning”, em *Communications in Computer and Information Science*, sér. Communications in computer and information science, Cham: Springer International Publishing, 2020, pp. 497–504.
- [2] S. Leclerc, E. Smistad, J. Pedrosa et al., “Deep learning for segmentation using an open large-scale dataset in 2D echocardiography”, *IEEE transactions on medical imaging*, v. 38, n. 9, pp. 2198–2210, 2019.
- [3] Y. Ali, F. Janabi-Sharifi e S. Beheshti, “Echocardiographic image segmentation using deep Res-U network”, en, *Biomed. Signal Process. Control*, v. 64, n. 102248, p. 102 248, fev. de 2021.
- [4] J. V. Stough, S. Raghunath, X. Zhang, J. M. Pfeifer, B. K. Fornwalt e C. M. Haggerty, “Left ventricular and atrial segmentation of 2D echocardiography with convolutional neural networks”, em *Medical Imaging 2020: Image Processing*, B. A. Landman e I. Išgum, ed., Houston, United States: SPIE, mar. de 2020.
- [5] X. Cui, P. Zhang, Y. Li et al., “MCAL: An anatomical knowledge learning model for myocardial segmentation in 2-D echocardiography”, en, *IEEE Trans. Ultrason. Ferroelectr. Freq. Control*, v. 69, n. 4, pp. 1277–1287, abr. de 2022.
- [6] S. Moradi, M. G. Oghli, A. Alizadehasl et al., “MFP-Unet: A novel deep learning based approach for left ventricle segmentation in echocardiography”, *Physica Medica*, v. 67, pp. 58–69, 2019, ISSN: 1120-1797. DOI: <https://doi.org/10.1016/j.ejmp.2019.10.001>. endereço: <https://www.sciencedirect.com/science/article/pii/S1120179719304508>.
- [7] Y. Chen, X. Zhang, C. M. Haggerty e J. V. Stough, “Assessing the generalizability of temporally coherent echocardiography video segmentation”, em *Medical Imaging 2021: Image Processing*, B. A. Landman e I. Išgum, ed., Online Only, United States: SPIE, fev. de 2021.
- [8] O. Ronneberger, P. Fischer e T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation”, em *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, sér. LNCS, (available on arXiv:1505.04597 [cs.CV]), vol. 9351, Springer, 2015, pp. 234–241. endereço: <http://lmb.informatik.uni-freiburg.de/Publications/2015/RFB15a>.
- [9] D. P. Kingma e J. Ba, *Adam: A Method for Stochastic Optimization*, 2014. DOI: 10.48550/ARXIV.1412.6980. endereço: <https://arxiv.org/abs/1412.6980>.